

Edu Predict

Solution d'IA prédictive et préventive de l'échec Scolaire



Mission : Prévenir l'échec scolaire

19 av.



Le problème


Comment de manière responsable et éthique mettre en oeuvre un système prédictif destiné à prévenir l'**échec scolaire**.

Prévenir pour éviter :

- l'échec, les coûts engendrés, la réputation de l'établissement...

Coût du décrochage scolaire par élève (Total: 340k€)

Impact financier majeur sur la société française



Comment ?

La donnée est l'élément essentiel pour réaliser de telle prédiction, mais...

- Comment éviter les **biais**,
- Comment parvenir à un résultat cohérent sans “**discriminer**”, “montrer du doigt”,
- Une simple analyse de notes est insuffisant au regard d'autres informations




Analyse exploratoire

Mais peut-on tout utiliser au risque d'introduire des biais de classification ?

Peut-on prendre le risque d'identifier des individus ?

Faut-il "exclure" les "HPI" pour ne pas risquer une mauvaise interprétation ?



Mettre en lumière les **corrélations** entre les données : notes, niveau d'éducation familial, composition et cellule familiale.

Ce que dit la réglementation : RGPD / AIAct

La réglementation est assez stricte au sujet des données qui peuvent ou non être utilisée dans l'élaboration d'un modèle d'IA :

Données à **risque discriminatoire** : sexe, âge, composition familiale, zones de résidence.

Données **privées** : activités professionnelles des parents, niveau d'éducation des parents, mode de garde... Ces informations doivent être minimisées, anonymisées,

Données **comportementales** : alcool, santé, relations, ces données sont proscrites ou restreintes dans le cadre d'une analyse prédictive,

Identifiants indirects : Combinaison de données permettant une identification indirecte.


Le traitement de la données

Etape 1 : Fusionner, nettoyer



0	18	4	4	2	2	0	4
1	17	1	1	1	2	0	5
2	15	1	1	1	2	3	4
3	15	4	2	1	3	0	3
4	16	3	3	1	2	0	4

0	18	4	4	2	2	0	4
1	17	1	1	1	2	0	5
2	15	1	1	1	2	3	4
3	15	4	2	1	3	0	3
4	16	3	3	1	2	0	4



Fusion,
Dédoublonnage,
Détection des données sensibles

Un dataset éthique et propre

```
GP,F,18,U,GT3,A,4,4,at_home,teacher,course,mother,2,2,0,yes,no,no,no,yes,yes,no,4,3,4,3,6,5,6,6,maths
GP,F,17,U,GT3,T,1,1,at_home,other,course,father,1,2,0,no,yes,no,no,no,yes,yes,5,3,3,3,4,5,5,6,maths
GP,F,15,U,LE3,T,1,1,at_home,other,other,mother,1,2,3,yes,no,yes,no,yes,yes,yes,4,3,2,3,10,7,8,10,maths
GP,F,15,U,GT3,T,4,2,health,services,home,mother,1,3,0,no,yes,yes,yes,yes,yes,3,2,2,5,2,15,14,15,maths
```

Transformer, optimiser

Etape 2 : Minimiser, anonymiser, encoder

Minimiser

Pour la conformité réglementaire :

- Réduction de la précision des données socio-économiques

Pour la performance statistique :

- Regrouper les catégories rares et éviter le sur-apprentissage

Anonymiser

Eviter la “réidentification” :

- sécurité éthique : rendre difficile l'identification personnelle par croisement de données,
- “top-coding” pour “noyer” certains profils qui ne seront pas traités comme individus mais comme “profils”

Encoder

Traduction en langage mathématique :

- La machine comprend 0 ou 1 plutôt que Oui ou Non,
- Chaque catégorie est encodée en valeur numérique pour permettre un calcul de poids

Aplanir, égaliser

Etape 3 : Compléter, réduire



Outliers


Pour éviter de traiter des données “extravagantes”, “hors norme” qui pourraient faire baisser la généralisation.

Imputers

Les données sont rarement complètes, l'imputation permet de remplacer (ou supprimer) les rangs de données pour optimiser l'entraînement.

Entraîner

Etape 3 : Définir un objet mathématique issue d'une observation



La sous-représentation

A partir d'un jeu de données, un des risques majeurs est la "sous-représentation" d'une ou plusieurs classes.

SMOTE (Synthetic Minority Oversampling Technic)

L'idée est d'augmenter artificiellement les classes sous-représentées en s'appuyant sur les classes minoritaires voisines.

Ce n'est pas juste une copie de données pour éviter l'over-fitting.

Le modèle résultant

Une structure

Un arbre de décision,
Une équation

Des paramètres

Les chiffres calculés
par l'algorithme choisi :
Une régression
logistique stockera des
"poids",
Un Random Forest
déterminera des seuils
de coupure,
...

Le modèle n'a plus besoin de données, il a acquis les informations, les a sérialisées, *mathématisées*, *binarisées*. C'est l'état à l'instant T de la connaissance acquise.

An aerial photograph of the New York City skyline at dusk. The Empire State Building is the central focus, its spire reaching into a dark, cloudy sky. The city's lights are visible, and the water of the harbor is in the background. The text 'Mise en oeuvre : Architecture et Conception' is overlaid in white, sans-serif font on the left side of the image.

Mise en oeuvre : Architecture et Conception

Conception *Industrielle*

De formation développeur, la conception est un élément essentiel de robustesse :

- Approche orientée objet,
- Respect des principes SOLID,
- Conception à base de Design Patterns

```
graph TD; A[Pipeline Builder and Runner] --- B[Director externalisé (yaml)]; B --- C[Chain of Responsibilities];
```


Pipeline Builder and Runner

Director externalisé (yaml)

Chain of Responsibilities

Chain of Responsibilities


Chaque étape est une responsabilité, elle gère un contexte partagé qui est transmis à l'étape suivante.



Pipeline

Le pipeline externalisé permet de modifier le comportement de l'application sans toucher au code.

En outre, il se met à jour automatiquement pour adapter les hyper paramètres grâce à *Optuna* et *Prefect*



Strategy

Les handlers peuvent se comporter dynamiquement différemment en utilisant une stratégie définie.

Il est possible de changer dynamiquement les stratégies :

- d'imputation (Imputation Intelligente, Imputation par médiane),
- de détection de valeurs hors normes (Outliers) : IQR, Isolation Forest,
- Apprentissage : Regression Logistique, Random Forest

L'orchestrateur permet de changer facilement la stratégie à utiliser, et potentiellement ajouter des étapes à tout instant.

Algorithmes


Approche 1 : Regression Logistique

Une approche mathématique probabiliste suivant une “ligne” de décision.


Approche 2 : Random Forest

Intelligence collective suivant un arbre de décision.

Logistic
Regression



Random Forest



Interprétabilité

Rapidité,
économique en
ressources

Arbres de décisions
votant, la majorité
l'emporte

Plus complexe dans
la détection de
relations
non-linéaire

Plus robuste vis à
vis des valeurs
aberrantes

Sélection dynamique du meilleur modèle

Le tracking

MLFlow track les modèles, les métriques et les artifacts

Le système

Récupère les meilleurs métriques à partir des données "éthiques".
Full Feature a été écarté

La précision (**accuracy**) a été retenue pour le modèle basé sur RandomForest


AUC a été retenu pour la régression.



Accuracy

Nombre de bonnes réponses sur le total des cas traités.

Risque : un modèle qui prédit "vrai" pour tout le monde aura un "accuracy" élevé, mais passera à côté complètement des échecs si les classes sont sous-représentées.



AUC
Zone sous la
Courbe

Le modèle classe, trie les classes. On évalue un score de risque.

Focus sur le choix des métriques

Accuracy

Random Forest

RF est un modèle robuste pour prendre des décisions tranchées, au risque de laisser passer des élèves à risque dans notre cas.

C'est la raison pour laquelle une courbe PR (Precision Recall) vient moduler le caractère "optimiste" de la prédiction.

AUC
Zone sous la
Courbe

Logistic Regression

Algorithme probabiliste à l'origine, il calcule un score. AUC permet de valider la fiabilité du score de risque attribué à chaque élève.

● LR_No_Sensitive	✓ 1 day ago	1.5s	🧠 model	0.9303675...	0.9784355...	0.8348623...
● RF_No_Sensitive	✓ 1 day ago	1.7s	🧠 model	0.9961315...	-	0.9909502...



Exploiter le(s) modèle(s)

Une API REST

Un frontend

- L'API expose les endpoints, est monitorée (Prometheus / Grafana)
- Le frontend propose une interface simple, abordable

Des personas

Les profils servant de tests pour les prédictions



Anna

17 ans

Assidue

Réside à proximité de l'
établissement

Un seul échec par le passé

Notes juste au dessus de
la moyenne



Cyril

20 ans

Chez sa mère

2 échecs

Des notes acceptables



Chloé

15 ans

Parents actifs

En zone rurale

Notes moyennes

Plusieurs absences



Charles

16 ans

Brillant

Peu de travail

Quelques absences

Parents inactifs

Analyse de risques

Risk Analysis

Model options

School

GP

Mother occupation

teacher

Absences

0

Gender

F

Father occupation

teacher

Note G1

10

Age

17

Week study time

2

Note G2

10

Area

U

?

Passed fails

0



AI Strategy

?

accuracy

Launch Prediction

Analyse de modèles



Données d'entraînements récupérées depuis MLFlow

Réentraînement



Training options labo

Load a version :

Base (pipeline_config.yaml)



Editor YAML (JSON format)

```
{
  "pipeline": {
    "data_processing": [
      {
        "step": "DataLoader",
        "params": {
          "files_to_load": {
            "maths": "datas/student-mat.csv",
            "por": "datas/student-por.csv"
          },
          "sep": ","
        }
      },
      {
        "step": "SensitiveDataHandler",
        "params": {
```



Create an Experiment



Train with this settings



eXplainable AI

Prédire c'est bien,
expliquer c'est mieux.

- Les métriques de prédictions permettent de déterminer les facteurs potentiels tendant à éviter l'échec,
- Ils peuvent aussi servir à améliorer le jeu de données initial, intégrer de nouvelles données

eXplainable AI

⚠ Risk detected (57.99%)

Factor

Fedu

This factor increase fail risk from 93.0%

Factor

goout

This factor increase fail risk from 62.6%

Factor

Pstatus_T

This factor increase fail risk from 53.8%

⚠ Risk detected (53.00%)

Factor

G2

Pregnant variable identified by forest (Importance: 0.35)

Factor

G1

Pregnant variable identified by forest (Importance: 0.22)

Factor

failures

Pregnant variable identified by forest (Importance: 0.05)

Optimisation

Un modèle est entraîné avec des hyperparamètres définis en amont, il devient statique.


Optuna permet d'ajuster dynamiquement ces paramètres.

- L'utilisation conjointe d'**Optuna** et **Prefect** offre au système une manière efficace et dynamique d'ajuster les paramètres d'entraînement,
- On évite en partie la dérive du modèle et l'entraînement sera réalisé à chaque mise à jour

Optuna

Permet de mettre à jour les hyper paramètres d'entraînement.

Dans le SI les hyper paramètres étant stockés dans un fichier de configuration, ce fichier sera mis à jour après 20 itérations.



Optuna

Après exécution en tâche de fond, le fichier de configuration a été mis à jour avec les hyper paramètres adaptés

```
params:
  rf_params:
    n_estimators: 200
    max_depth: 8
  min_samples_leaf: 20
  min_samples_split: 40
  max_features: "sqrt"
  class_weight: "balanced"
  bootstrap: true
  oob_score: true
  random_state: 42
  lr_params:
    C: 1.0
    solver: "lbfgs"
```

```
48 | params:
49+ |   lr_params:
50+ |     C: 0.02127538093709556
51+ |     max_iter: 2304
52+ |     solver: lbfgs
53+ |   rf_params:
54+ |     bootstrap: true
55+ |     class_weight: balanced
56+ |     max_depth: 5
57+ |     max_features: sqrt
58+ |     min_samples_leaf: 20
59+ |     min_samples_split: 7
60+ |     n_estimators: 107
61+ |
62+ |     oob_score: true
        random_state: 42
```



Déploiement Conteneurisation et CD

La solution étant en place, un processus de CI/CD peut être préparé afin de déployer automatiquement les artefacts en production.

Docker

Les composants sont “dockerisés” afin d’être facilement déployables en environnement de production.

docker-compose

Construit les images et “monte” les services

☐	▼	☐	<u>final_notebook</u>	-	-	-
☐		☐	edupredict_grafana	41b8a75f0c9d	grafana/grafana	3000:3000
☐		☐	edupredict_ui	f9c5616993c4	final_notebook	8501:8501
☐		☐	edupredict_api	b3835ca4b55c	final_notebook	8000:8000
☐		☐	edupredict_prometheus	a676acaaf39a	prom/prometheus	9090:9090


Github actions

Les actions Github vont autoriser l'enchaînement d'étapes pour :

- Jouer les tests,
- Initialiser un entraînement optimisé,
- Tracker les actions dans Discord,
- Déployer la solution complète

Confidentialité Github :

Name 	Last updated
 CICD_PIPELINE_DISCORD	now  



Pour assurer une compatibilité avec Gitlab, un fichier ".gitlab-ci.yml" a été généré, permettant aisément de passer d'une forge à une autre.

En conclusion :

A partir de l'élaboration d'un modèle prédictif, j'en suis arrivé à concevoir une solution modulaire, permettant de tester, ajuster, modifier aisément un processus et intégrer un aperçu XAI.

- Le jeu de données est trop peu fourni pour optimiser les prédictions (risque d'over-fitting),
- Une distribution normale peut être traitée avec un algorithme de Régression Linéaire simple, afin d'optimiser la ressource,