


Biais-variance — *sur- et sous-apprentissage*

Pourquoi un modèle généralise (ou pas) · Marianne A. · concept transversal ML

Le cadre. L'erreur qu'un modèle commet sur des données nouvelles se décompose en trois termes : $\text{erreur} = \text{biais}^2 + \text{variance} + \text{bruit irréductible}$. Le **bruit** est incompressible (les données sont imparfaites) ; il ne reste donc à agir que sur le **biais** et la **variance**. Le **sous-apprentissage** (*underfitting*) vient d'un modèle **trop simple** : biais élevé, il rate les motifs, même sur le train. Le **sur-apprentissage** (*overfitting*) vient d'un modèle **trop complexe** : variance élevée, il apprend le bruit du train et échoue à généraliser. Tout l'enjeu est de **diagnostiquer** lequel des deux domine, puis de le **corriger**.

Repère Un bon modèle minimise l'erreur de **validation**, pas celle du **train**. Un train parfait avec une validation médiocre est le signe classique du sur-apprentissage.

1 Le compromis biais-variance



Biais. Erreur due à des hypothèses trop rigides du modèle : il ne peut pas capturer la vraie relation, donc il se trompe de façon systématique (à gauche de la courbe). **Variance.** Sensibilité excessive aux fluctuations du jeu d'entraînement : le modèle colle au bruit, si bien qu'un autre échantillon donnerait un modèle très différent (à droite). L'erreur d'entraînement **décroît continuellement** quand on complexifie ; l'erreur de validation forme un **U** — c'est son creux qu'on vise.

2 Diagnostic par l'écart train / validation

SITUATION	DIAGNOSTIC	QUE FAIRE
Erreur train élevée ET validation élevée (les deux proches)	Sous-apprentissage (biais)	Modèle plus complexe, ajouter des features pertinentes, réduire la régularisation, entraîner plus longtemps.
Erreur train faible MAIS validation élevée (grand écart)	Sur-apprentissage (variance)	Plus de données, augmenter la régularisation, modèle plus simple, retirer des features, <i>early stopping</i> .
Erreur train faible ET validation faible	Bon équilibre	C'est l'objectif : le modèle a appris les motifs sans coller au bruit. Rien à corriger.

3 Les leviers et leur effet

LEVIER	EFFET
Plus de régularisation (L1/L2, max_depth↓)	variance ↓ (biais ↑) — on bride le modèle pour qu'il colle moins au bruit.
Plus de données d'entraînement	variance ↓ — le modèle voit assez d'exemples pour ne pas mémoriser les cas particuliers.
Ajouter des features pertinentes	biais ↓ (risque variance ↑) — on donne au modèle de quoi capturer la vraie relation.
Augmenter la complexité (profondeur d'arbre, degré)	biais ↓, variance ↑ — plus d'expressivité, mais plus de risque de sur-apprendre.
Bagging / Random Forest	variance ↓ — moyenner plusieurs arbres décorrélés stabilise les prédictions.
Boosting	biais ↓ — on corrige les erreurs successives (surveiller la variance).
<i>Early stopping</i>	variance ↓ — on arrête l'entraînement avant que le modèle ne commence à mémoriser le bruit.

4 Lire les courbes d'apprentissage

Une **courbe d'apprentissage** (`learning_curve`) trace le score du modèle en fonction de la **taille du jeu d'entraînement** : on entraîne sur des sous-ensembles de plus en plus grands et on relève les scores de train et de validation. La forme des deux courbes révèle le diagnostic :

Elles convergent vers un score bas. Train et validation se rejoignent, mais à un niveau médiocre, et ajouter des données n'améliore plus rien → c'est un problème de **biais**. Il faut *complexifier* le modèle (plus de features, plus de capacité, moins de régularisation).

Un grand écart persistant. Le train reste très bon, la validation reste nettement en dessous, et l'écart ne se referme pas → c'est un problème de **variance**. Il faut *plus de données* ou davantage de *régularisation* (et souvent un modèle plus simple).

```
from sklearn.model_selection import learning_curve

train_sizes, train_sc, val_sc = learning_curve(pipe, X_train, y_train, cv=5, scoring="f1_macro")
```

La règle d'or. Vise le **creux de la courbe de validation** · diagnostique via l'**écart train / validation** · corrige selon la cause : si c'est du **biais**, complexifie (features, capacité, moins de régularisation) ; si c'est de la **variance**, régularise ou apporte plus de données (et simplifie).

À retenir. biais = trop simple, variance = trop complexe ; on lit l'écart train / validation pour savoir lequel domine, puis on complexifie contre le biais ou on régularise (plus de données) contre la **Fiche 7/12 · Série ML** variance — le bon modèle est celui qui minimise l'erreur de validation, pas celle du train.