

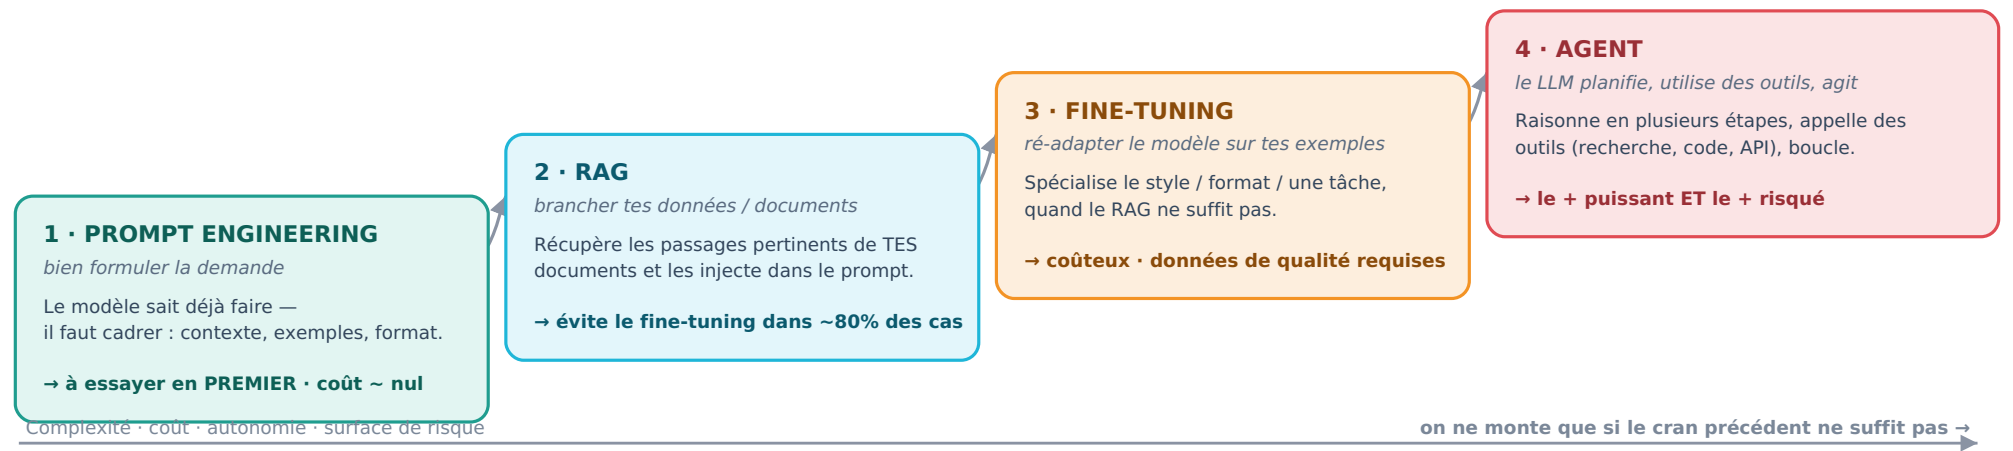
GenAI / LLM / Agents — quand & comment

L'échelle d'adaptation, du plus simple au plus lourd · Marianne A. · fiche compagnon de « Choisir la bonne famille de ML »

Pourquoi une fiche à part. La GenAI ne s'entraîne pas comme un modèle tabulaire : on part d'un **modèle de fondation** déjà entraîné (LLM, diffusion) et on l'**adapte**. Pas de `train_test_split` ni de F1 macro ; l'enjeu est de *brancher le bon contexte* et d'*évaluer une sortie ouverte*. Cette fiche donne l'échelle d'adaptation et les pièges à connaître.

Étape 0 Rappel : **un LLM n'est pas la réponse à un problème tabulaire**. Si tu prédis ou classes à partir de colonnes, reviens au ML classique (fiche « Choisir la bonne famille de ML »). La GenAI, c'est quand il faut *générer ou comprendre du contenu*.

1 L'échelle d'adaptation : monter d'un cran seulement si nécessaire



2 Les 4 niveaux en détail

NIVEAU	EN QUOI ÇA CONSISTE	QUAND L'UTILISER	COÛT / EFFORT	PIÈGE PRINCIPAL
Prompt engineering	Rédiger de bonnes instructions : contexte, exemples (<i>few-shot</i>), format de sortie attendu.	Toujours en premier — souvent le modèle sait déjà, il suffit de cadrer la demande.	Très faible (aucune infra).	Fragile : un changement de modèle peut casser le prompt ; peu reproductible.

NIVEAU	EN QUOI ÇA CONSISTE	QUAND L'UTILISER	COÛT / EFFORT	PIÈGE PRINCIPAL
RAG Retrieval-Augmented Generation	Récupérer les passages pertinents dans tes documents et les injecter dans le prompt au moment de la question.	Répondre sur des connaissances privées, métier ou plus récentes que le modèle.	Modéré (base vectorielle, ingestion des docs).	La qualité dépend de la recherche : si le bon passage n'est pas retrouvé, le modèle invente.
Fine-tuning	Poursuivre l'entraînement du modèle sur tes exemples pour spécialiser un style, un format ou une tâche .	Besoin d'un comportement très constant ou d'un ton spécifique, quand le RAG ne suffit pas.	Élevé (données labellisées, calcul, MLOps).	Coûteux à maintenir ; n'apporte pas de connaissance factuelle fraîche (ça, c'est le rôle du RAG).
Agent	Le LLM raisonne en plusieurs étapes , choisit et appelle des outils (recherche, code, API), et boucle jusqu'au but.	Tâches multi-étapes avec actions sur le monde — pas une simple réponse.	Élevé & variable (appels multiples).	Fiabilité, coût et latence qui explosent ; boucles ; surface de sécurité élargie (bloc 3).

3 Pièges & points de vigilance propres à la GenAI

POINT DE VIGILANCE	POURQUOI	LE RÉFLEXE
Hallucinations	Le modèle produit du <i>plausible</i> , pas du <i>vrai</i> — avec aplomb.	Ancrer sur des sources (RAG), citer, vérifier. Un LLM n'est pas un moteur de vérité .
Coût & latence	Chaque appel = des tokens facturés ; un agent multiplie les appels.	Mesurer le coût par appel, mettre du cache, choisir la taille de modèle selon le besoin réel.
Confidentialité	Envoyer des données sensibles à un fournisseur externe est un risque juridique et métier.	Anonymiser, préférer un modèle privé/hébergé, vérifier les clauses de traitement des données.
Évaluation	Pas de F1 ici : la qualité d'une sortie ouverte est en partie subjective.	Jeu de tests, critères explicites, revue humaine, <i>LLM-as-judge</i> (avec prudence).
Reproductibilité	Température, version du modèle et prompt → sorties variables d'une fois à l'autre.	Fixer les versions, journaliser prompts & paramètres (c'est le rôle du LLMOps).
Sécurité	<i>Prompt injection</i> — surtout quand un agent dispose d'outils et d'accès.	Valider les entrées, restreindre outils/permissions, garder un humain dans la boucle pour les actions sensibles.
Conformité (AI Act)	Transparence (prévenir qu'on parle à une IA), marquage des contenus générés, obligations GPAI.	Intégrer la conformité dès la conception — cf. la grille de classification AI Act.

La règle d'or GenAI. Monte l'échelle par le bas : **prompt** d'abord, **RAG** ensuite, **fine-tuning** si vraiment nécessaire, **agent** en dernier. Un LLM n'est ni un moteur de vérité ni une base de données — garde un humain dans la boucle pour les décisions sensibles. Et comme pour le ML classique, il faut de l'ops : le **LLMOps** (versioning des prompts, évaluation continue, monitoring des coûts et de la qualité) est l'équivalent du MLOps pour la GenAI.

À retenir. GenAI = adapter un modèle de fondation, pas entraîner de zéro · l'échelle prompt → RAG → fine-tuning → agent se gravit *par le bas* · RAG pour la connaissance, fine-tuning pour le comportement · hallucinations, coût, confidentialité, sécurité et conformité sont les vrais sujets · et un LLM ne remplace pas un bon modèle tabulaire. **Fiche 12/12 · Série ML**