


# GenAI / LLM / Agents — quand & comment

L'échelle d'adaptation, du plus simple au plus lourd · Marianne A. · fiche compagnon de « Choisir la bonne famille de ML »

**Pourquoi une fiche à part.** La GenAI ne s'entraîne pas comme un modèle tabulaire : on part d'un **modèle de fondation** déjà entraîné (LLM, diffusion) et on l'**adapte**. Pas de `train_test_split` ni de F1 macro ; l'enjeu est de *brancher le bon contexte* et d'*évaluer une sortie ouverte*. Cette fiche donne l'échelle d'adaptation et les pièges à connaître.

**Étape 0** Rappel : **un LLM n'est pas la réponse à un problème tabulaire**. Si tu prédis ou classes à partir de colonnes, reviens au ML classique (fiche « Choisir la bonne famille de ML »). La GenAI, c'est quand il faut *générer ou comprendre du contenu*.

## 1 L'échelle d'adaptation : monter d'un cran seulement si nécessaire



## 2 Les 4 niveaux en détail

| NIVEAU             | EN QUOI ÇA CONSISTE                                                                                | QUAND L'UTILISER                                                                   | COÛT / EFFORT               | PIÈGE PRINCIPAL                                                              |
|--------------------|----------------------------------------------------------------------------------------------------|------------------------------------------------------------------------------------|-----------------------------|------------------------------------------------------------------------------|
| Prompt engineering | Rédiger de bonnes instructions : contexte, exemples ( <i>few-shot</i> ), format de sortie attendu. | Toujours en premier — souvent le modèle sait déjà, il suffit de cadrer la demande. | Très faible (aucune infra). | Fragile : un changement de modèle peut casser le prompt ; peu reproductible. |
|                    |                                                                                                    |                                                                                    |                             |                                                                              |
|                    |                                                                                                    |                                                                                    |                             |                                                                              |
|                    |                                                                                                    |                                                                                    |                             |                                                                              |

| NIVEAU                                              | EN QUOI ÇA CONSISTE                                                                                                        | QUAND L'UTILISER                                                                                  | COÛT / EFFORT                                  | PIÈGE PRINCIPAL                                                                                          |
|-----------------------------------------------------|----------------------------------------------------------------------------------------------------------------------------|---------------------------------------------------------------------------------------------------|------------------------------------------------|----------------------------------------------------------------------------------------------------------|
| <b>RAG</b><br><b>Retrieval-Augmented Generation</b> | Récupérer les passages pertinents dans <b>tes</b> documents et les injecter dans le prompt au moment de la question.       | Répondre sur des connaissances <b>privées, métier ou plus récentes</b> que le modèle.             | Modéré (base vectorielle, ingestion des docs). | La qualité dépend de la recherche : si le bon passage n'est pas retrouvé, le modèle invente.             |
| <b>Fine-tuning</b>                                  | Poursuivre l'entraînement du modèle sur tes exemples pour spécialiser un <b>style, un format ou une tâche</b> .            | Besoin d'un comportement très <b>constant</b> ou d'un ton spécifique, quand le RAG ne suffit pas. | Élevé (données labellisées, calcul, MLOps).    | Coûteux à maintenir ; n'apporte <b>pas</b> de connaissance factuelle fraîche (ça, c'est le rôle du RAG). |
| <b>Agent</b>                                        | Le LLM <b>raisonne en plusieurs étapes</b> , choisit et appelle des outils (recherche, code, API), et boucle jusqu'au but. | Tâches <b>multi-étapes avec actions</b> sur le monde — pas une simple réponse.                    | Élevé & variable (appels multiples).           | <b>Fiabilité, coût et latence qui explosent ; boucles ; surface de sécurité élargie (bloc 3).</b>        |

3 Pièges & points de vigilance propres à la GenAI

| POINT DE VIGILANCE         | POURQUOI                                                                                       | LE RÉFLEXE                                                                                                              |
|----------------------------|------------------------------------------------------------------------------------------------|-------------------------------------------------------------------------------------------------------------------------|
| <b>Hallucinations</b>      | Le modèle produit du <i>plausible</i> , pas du <i>vrai</i> — avec aplomb.                      | Ancrer sur des sources (RAG), citer, vérifier. Un LLM n'est <b>pas un moteur de vérité</b> .                            |
| <b>Coût &amp; latence</b>  | Chaque appel = des tokens facturés ; un agent multiplie les appels.                            | Mesurer le coût par appel, mettre du cache, choisir la <b>taille de modèle</b> selon le besoin réel.                    |
| <b>Confidentialité</b>     | Envoyer des données sensibles à un fournisseur externe est un risque juridique et métier.      | Anonymiser, préférer un modèle privé/hébergé, vérifier les clauses de traitement des données.                           |
| <b>Évaluation</b>          | Pas de F1 ici : la qualité d'une sortie ouverte est en partie subjective.                      | Jeu de tests, critères explicites, revue humaine, <i>LLM-as-judge</i> (avec prudence).                                  |
| <b>Reproductibilité</b>    | Température, version du modèle et prompt → sorties variables d'une fois à l'autre.             | Fixer les versions, journaliser prompts & paramètres (c'est le rôle du <b>LLMOps</b> ).                                 |
| <b>Sécurité</b>            | <i>Prompt injection</i> — surtout quand un agent dispose d'outils et d'accès.                  | Valider les entrées, restreindre outils/permissions, <b>garder un humain dans la boucle</b> pour les actions sensibles. |
| <b>Conformité (AI Act)</b> | Transparence (prévenir qu'on parle à une IA), marquage des contenus générés, obligations GPAI. | Intégrer la conformité dès la conception — cf. la grille de classification AI Act.                                      |

**La règle d'or GenAI.** Monte l'échelle par le bas : **prompt** d'abord, **RAG** ensuite, **fine-tuning** si vraiment nécessaire, **agent** en dernier. Un LLM n'est ni un moteur de vérité ni une base de données — garde un humain dans la boucle pour les décisions sensibles. Et comme pour le ML classique, il faut de l'ops : le **LLMOps** (versioning des prompts, évaluation continue, monitoring des coûts et de la qualité) est l'équivalent du MLOps pour la GenAI.

---

**À retenir.** GenAI = adapter un modèle de fondation, pas entraîner de zéro · l'échelle prompt → RAG → fine-tuning → agent se gravit *par le bas* · RAG pour la connaissance, fine-tuning pour le comportement · hallucinations, coût, confidentialité, sécurité et conformité sont les vrais sujets · et un LLM ne remplace pas un bon modèle tabulaire. **Fiche 13/13 · Série ML**