

# Interprétabilité & XAI

Expliquer POURQUOI un modèle prédit · Marianne A. · confiance métier & conformité (AI Act)

**Pourquoi expliquer ?** Expliquer les prédictions est exigé pour la **confiance métier** et la **conformité** (AI Act, transparence). Deux voies possibles : des modèles *intrinsèquement interprétables*, ou des méthodes *post-hoc* appliquées à des boîtes noires.

**Distinction** Interprétabilité **GLOBALE** (comment le modèle se comporte en général) vs **LOCALE** (pourquoi *CETTE* prédiction).

## 1 Deux familles

| APPROCHE                                            | EXEMPLES                                                                             | AVANTAGE / LIMITE                                                                     |
|-----------------------------------------------------|--------------------------------------------------------------------------------------|---------------------------------------------------------------------------------------|
| <b>Intrinsèque</b><br>le modèle s'explique lui-même | Régression linéaire / logistique (coefficients), arbre de décision (règles).         | <b>Transparent</b> : l'explication est le modèle lui-même ; parfois moins performant. |
| <b>Post-hoc</b><br>expliquer une boîte noire        | Feature importance, SHAP, LIME, PDP appliqués à RF / boosting / réseaux de neurones. | S'applique à <b>tout</b> modèle ; mais l'explication reste <b>approximative</b> .     |

## 2 Les méthodes post-hoc

| MÉTHODE                                          | CE QUE ÇA DONNE                                                                   | PORTÉE           | À SAVOIR                                                                                 |
|--------------------------------------------------|-----------------------------------------------------------------------------------|------------------|------------------------------------------------------------------------------------------|
| <b>Importance des variables</b><br>(permutation) | Importance globale de chaque variable pour le modèle.                             | Globale          | Préférer la <b>permutation</b> à l'importance par impureté (biaisée par la cardinalité). |
| <b>SHAP</b>                                      | Contribution de chaque variable à chaque prédiction (théorie des jeux).           | Globale + locale | <b>Référence</b> , mais coûteux en calcul.                                               |
| <b>LIME</b>                                      | Approxime localement la boîte noire par un modèle simple autour d'une prédiction. | Locale           | Rapide mais <b>instable</b> (varie selon l'échantillonnage).                             |
| <b>PDP / ICE</b>                                 | Effet marginal d'une variable sur la prédiction.                                  | Globale          | <b>Trompeur</b> si variables corrélées (suppose l'indépendance).                         |

### 3 Global vs local : quand utiliser quoi

#### GLOBAL

comment le modèle se comporte en général

#### LOCAL

pourquoi CETTE prédiction précise

| BESOIN                                                      | NIVEAU | OUTIL                                     |
|-------------------------------------------------------------|--------|-------------------------------------------|
| Comprendre les facteurs dominants du modèle.                | Global | Importance de permutation, SHAP (résumé). |
| Justifier une décision individuelle (ex : refus de crédit). | Local  | SHAP (valeurs locales), LIME.             |
| Voir l'effet d'une variable.                                | Global | PDP / ICE.                                |

### 4 Pièges

| LE PIÈGE                             | LA RÉALITÉ                                                                                 |
|--------------------------------------|--------------------------------------------------------------------------------------------|
| Importance par impureté              | Biaisée vers les variables à forte cardinalité → utiliser la <b>permutation</b> .          |
| Corrélation $\neq$ causalité         | Une variable « importante » n'est pas forcément une cause → prudence dans les conclusions. |
| LIME instable                        | Deux exécutions peuvent différer → vérifier la robustesse.                                 |
| PDP avec variables corrélées         | Effets trompeurs → croiser avec ICE / SHAP.                                                |
| « Interprétable » $\neq$ « correct » | Un modèle explicable peut être faux ; l'interprétabilité ne remplace pas l'évaluation.     |

**Note conformité.** L'AI Act impose de la **transparence** : informer l'utilisateur qu'il interagit avec une IA, et documenter les systèmes à haut risque. L'explicabilité y contribue directement.

**La règle d'or.** Si l'explicabilité est **cruciale** (réglementaire, décision sensible), privilégier un modèle *intrinsèquement interprétable* · sinon, expliquer la boîte noire avec **SHAP** (global + local), en gardant à l'esprit que ces explications restent des *approximations*.

---

**À retenir.** Interprétable par construction quand la décision l'exige, boîte noire expliquée par SHAP sinon — global pour comprendre le modèle, local pour justifier une prédiction, sans jamais confondre explicabilité et exactitude. **Fiche 11/13 · Série ML**