

Métriques — *comprendre, choisir, référence*

De la matrice de confusion à l'arbre de décision, puis toutes les définitions · Marianne A. · complète M1 et la fiche « Métriques de régression »

Le réflexe n'est pas de « connaître toutes les métriques », c'est de « choisir la bonne, et savoir pourquoi ». Une métrique traduit ce qui compte dans le *problème métier* : le coût d'une erreur, l'importance de la classe rare, la fiabilité des probabilités, la stabilité dans le temps.

Plan 1-3 : comprendre & choisir (partie apprentissage) · 4-6 : la référence complète, avec définitions, formules et pièges.

1 Comprendre — tout part de la matrice de confusion

	RÉEL +	RÉEL -
PRÉDIT +	VP	FP
PRÉDIT -	FN	VN

Précision
« Quand je dis +, ai-je raison ? »
 $VP / (VP + FP)$

Rappel (sensibilité)
« Parmi les + réels, combien j'en trouve ? »
 $VP / (VP + FN)$

Spécificité
« Parmi les -, combien je reconnais ? »
 $VN / (VN + FP)$

Accuracy
« Globalement, combien de fois ai-je raison ? »
 $(VP + VN) / total$

Comprends parfaitement ce bloc et tu as compris l'essentiel des métriques de classification. Le **F1** combine précision et rappel (moyenne harmonique) ; le **F1 macro** fait la moyenne des F1 de chaque classe, à poids égal.

2 Choisir — l'arbre de décision « quelle métrique ? »

MON PROBLÈME EST UNE CLASSIFICATION

régression ? → fiche « Métriques de régression »

Les classes sont-elles déséquilibrées ?

NON

OUI

Classes équilibrées

Accuracy · F1 · ROC-AUC

l'accuracy est fiable ici

Déséquilibre (classe rare)

F1 macro · Rappel de la classe rare · PR-AUC · MCC

ne regarde JAMAIS l'accuracy seule

Une erreur coûte-t-elle plus cher ?

Faux positif coûteux → **Précision**

Faux négatif coûteux → **Rappel**

on ajuste alors le seuil de décision.

Besoin de probabilités fiables ?

Pas juste une classe, mais une probabilité juste →

Log loss · Brier + courbe de calibration.

Modèle surveillé en production ?

Vérifier que les données ne dérivent pas →

PSI · CSI + tests de drift (**KS**, χ^2).

Classe rare ? Ne regarde jamais l'accuracy seule. Le réflexe : **rappel de la classe rare + F1 macro + PR-AUC**.

3 Les métriques par niveau de priorité

À maîtriser

- Matrice de confusion
- Accuracy
- Précision & Rappel
- F1 · F1 macro
- ROC-AUC · PR-AUC
- Log loss / Brier

Le socle : savoir les calculer, les lire et les choisir seul-e.

À connaître

- Spécificité · Balanced accuracy
- MCC (Matthews)
- KS · Gini
- PSI · CSI
- Test du χ^2 · p-value

Vues dans les modules : savoir ce que ça mesure et quand ça sert.

Culture ML — à reconnaître

- Cohen's kappa
- Divergence KL
- Divergence JS
- Distance de Wasserstein

Savoir que ça existe et à quoi ça sert, sans devoir l'appliquer.

4 Référence — classification (à partir de la matrice de confusion, dépend d'un seuil)

MÉTRIQUE	DÉFINITION	QUAND L'UTILISER	PIÈGE
Accuracy (VP+VN)/total	Proportion de prédictions correctes.	Classes équilibrées, coûts d'erreur symétriques.	Trompeuse en déséquilibre (95 % de négatifs → 95 % en prédisant « non »).
Précision VP/(VP+FP)	Parmi les cas prédits positifs , combien le sont vraiment.	Quand un faux positif coûte cher (bloquer un bon client).	Se lit par classe ; monte si on prédit « positif » prudemment.
Rappel / Sensibilité (TPR) VP/(VP+FN)	Parmi les vrais positifs , combien sont retrouvés.	Quand rater un positif coûte cher (fraude, défaut, maladie).	Monte si on prédit « positif » largement (au prix de la précision).
Spécificité (TNR) VN/(VN+FP)	Parmi les vrais négatifs, combien sont bien classés.	Quand les fausses alertes doivent rester rares.	Complément du taux de faux positifs (1 – spécificité).
F1-score $2 \cdot P \cdot R / (P + R)$	Moyenne harmonique précision × rappel.	Compromis P/R sur une classe, en déséquilibre modéré.	Ignore les vrais négatifs ; à lire par classe.
F1 macro moyenne des F1 par classe	Moyenne des F1 à poids égal entre classes.	Le réflexe en déséquilibre : la classe rare pèse autant.	Ne pas confondre avec F1 <i>weighted</i> (pondéré par effectif → optimiste).
Balanced accuracy moyenne des rappels par classe	Moyenne du rappel de chaque classe.	Alternative simple à l'accuracy en déséquilibre.	Ne dit rien sur la précision / les faux positifs.
MCC (Matthews) corrélation préd/réel, [-1,1]	Corrélation entre prédictions et vérité, utilise les 4 cases.	Métrique unique robuste même en fort déséquilibre.	Moins intuitive à communiquer qu'un F1.
Cohen's kappa accord au-delà du hasard	Accord observé corrigé de l'accord dû au hasard.	Comparer à une baseline « au hasard » ; accord annotateurs.	Sensible à la prévalence des classes.

5 Référence — scores & probabilités (sans seuil)

MÉTRIQUE	DÉFINITION	QUAND L'UTILISER	PIÈGE
ROC-AUC aire sous TPR vs FPR	Probabilité qu'un positif tiré au hasard ait un score > un négatif. 0,5 = hasard, 1 = parfait.	Comparer des modèles en classes équilibrées , indépendamment du seuil.	Optimiste en fort déséquilibre : préférer la PR-AUC.

MÉTRIQUE	DÉFINITION	QUAND L'UTILISER	PIÈGE
PR-AUC (Average Precision) aire sous précision-rappel	Résume le compromis précision/rappel sur tous les seuils.	Déséquilibre et quand la classe positive est celle qui compte.	La baseline = prévalence (pas 0,5) ; à comparer à ça.
KS (Kolmogorov-Smirnov) écart max des CDF pos/neg	Écart maximal entre les distributions cumulées des scores des positifs et des négatifs → séparation.	Scoring / octroi de crédit : séparation bons/mauvais.	Un seul point de la courbe ; à compléter par AUC/PR.
Gini $2 \cdot \text{AUC} - 1$	Reformulation de l'AUC (0 = hasard, 1 = parfait), usuelle en scoring.	Milieu bancaire / risque, par convention.	Équivalent à l'AUC : mêmes limites en déséquilibre.
Log loss entropie croisée	Pénalise d'autant plus qu'on est confiant <i>et</i> faux.	Quand on optimise / compare des probabilités .	Très sensible aux prédictions extrêmes mal calibrées.
Brier score MSE des probabilités	Erreur quadratique moyenne entre proba prédite et réalité (0/1).	Mesurer la calibration des probabilités.	Se combine avec une courbe de calibration.
ROC-AUC ou PR-AUC ? En classes équilibrées, les deux racontent la même histoire. En fort déséquilibre , la ROC-AUC reste flatteuse (beaucoup de vrais négatifs faciles) alors que la PR-AUC révèle la vraie difficulté sur la classe rare.			

6 Référence — stabilité, dérive & tests statistiques (production)			
MESURE	DÉFINITION	QUAND L'UTILISER	PIÈGE / SEUIL
PSI (Population Stability Index) $\sum (a-e) \cdot \ln(a/e)$ sur les bins	Compare la distribution d'un score entre référence et période actuelle.	Monitoring de dérive du score en production.	<0,1 stable · 0,1-0,25 à surveiller · >0,25 dérive forte.
CSI (Characteristic Stability Index) PSI sur une variable	Même calcul que le PSI mais sur une variable d'entrée .	Repérer quelle variable dérive.	Mêmes seuils que le PSI ; feature par feature.
Test de Kolmogorov-Smirnov 2 échantillons → stat + p	Teste si deux échantillons d'une variable continue ont la même distribution.	Détecter le drift d'une variable numérique.	Sur gros volumes, détecte des écarts minuscules.

MESURE	DÉFINITION	QUAND L'UTILISER	PIÈGE / SEUIL
Test du Chi² (χ^2) contingence → stat + p	Teste l'indépendance / l'homogénéité de distributions catégorielles .	Drift d'une variable catégorielle ; lien variable ↔ cible.	Sensible aux petits effectifs ; sur gros N tout devient « significatif ».
p-value P(observé H0 vraie)	Probabilité d'observer un résultat au moins aussi extrême si l'hypothèse nulle est vraie.	Décider si un écart est statistiquement notable (souvent 0,05).	≠ taille d'effet ni importance pratique ; sur gros volumes, sur-détecte.
KL / JS · Wasserstein distances entre distributions	Quantifie l'écart entre deux distributions (référence vs actuelle).	Drift fin ; comparaison de distributions (données synthétiques).	KL non symétrique et instable si supports disjoints ; JS/Wasserstein plus robustes.
La règle PSI, en un coup d'œil : < 0,10 → stable · 0,10-0,25 → dérive modérée, investiguer (quelle feature via le CSI ?) · > 0,25 → dérive importante, le modèle décroche probablement → envisager un réentraînement.			

Les 5 réflexes à retenir

- 1. La métrique dépend du **problème métier**, pas de l'habitude.
- 2. **Faux positif** coûteux → **précision** · **Faux négatif** coûteux → **rappel**.
- 3. **Classe rare** → méfie-toi de l'accuracy, regarde **F1 macro + rappel + PR-AUC**.
- 4. Besoin de **probabilités fiables** → log loss / Brier + calibration.
- 5. **Production** → surveille la dérive (PSI/CSI) ; une p-value « significative » ne veut pas dire « importante ».