


# Techniques RAG — Retrieval-Augmented Generation

Améliorer chaque étape du pipeline, du chunking à l'évaluation · Marianne A. · annexe de la fiche « GenAI / LLM / Agents »

**Le principe.** Le RAG *augmente* un LLM en lui fournissant, au moment de la question, des passages pertinents tirés de **tes** données. Deux temps : une phase **hors-ligne** (indexer les documents) et une phase **en ligne** (récupérer puis générer). La qualité d'un RAG = qualité de la *récupération* × qualité de la *génération* — la plupart des échecs viennent de la récupération.

**Rappel** Le RAG est le 2<sup>e</sup> barreau de l'échelle GenAI (après le prompt, avant le fine-tuning). On commence **simple** et on ajoute des techniques *là où l'évaluation montre le point faible*, pas partout.

## 1 Le pipeline RAG : indexer (hors-ligne) puis récupérer & générer (en ligne)



On peut agir sur CHAQUE boîte pour améliorer le RAG — c'est l'objet des blocs suivants.

## 2 Les techniques, étape par étape

| ÉTAPE      | TECHNIQUE                                     | CE QUE ÇA FAIT                                                                                    | QUAND L'UTILISER                                                         |
|------------|-----------------------------------------------|---------------------------------------------------------------------------------------------------|--------------------------------------------------------------------------|
| Indexation | Chunking sémantique / à taille fixe + overlap | Découper les documents en morceaux cohérents ; le chevauchement évite de couper une idée en deux. | Toujours — le chunking est le levier n°1, souvent sous-estimé.           |
| Indexation | Parent-document / contextual headers          | Récupérer un petit chunk précis mais fournir au LLM son contexte parent (section, titre).         | Documents longs et structurés ; quand les chunks isolés perdent le sens. |

| ÉTAPE            | TECHNIQUE                                       | CE QUE ÇA FAIT                                                                                                        | QUAND L'UTILISER                                                                      |
|------------------|-------------------------------------------------|-----------------------------------------------------------------------------------------------------------------------|---------------------------------------------------------------------------------------|
| Requête          | Réécriture & expansion de requête               | Reformuler / enrichir la question de l'utilisateur avant la recherche.                                                | Questions vagues, mal formulées, ou riches en synonymes.                              |
| Requête          | HyDE (Hypothetical Document Embeddings)         | Faire générer par le LLM une réponse hypothétique, puis chercher les documents proches de CETTE réponse.              | Quand la question et les documents utilisent un vocabulaire différent.                |
| Requête          | Décomposition / multi-query                     | Éclater une question complexe en sous-questions, récupérer pour chacune, fusionner.                                   | Questions multi-critères ou « multi-hop » (plusieurs faits à relier).                 |
| Récupération     | Recherche hybride (dense + BM25)                | Combiner similarité sémantique (embeddings) et correspondance de mots-clés (BM25).                                    | Presque toujours : rattrape les cas où l'un des deux échoue (noms, sigles, chiffres). |
| Récupération     | Filtrage par métadonnées + MMR                  | Restreindre par date/source/type ; MMR diversifie les résultats pour éviter les doublons.                             | Grandes bases ; besoin de fraîcheur, de périmètre, ou de diversité.                   |
| Re-ranking       | Cross-encoder / RAG-Fusion                      | Ré-ordonner finement les passages récupérés par pertinence réelle (modèle dédié, ou fusion de plusieurs classements). | Quand le top-k contient les bons passages mais mal classés / noyés.                   |
| Génération       | Prompt ancré + citations + compression          | Injecter le contexte, imposer de citer les sources, compresser pour ne garder que l'utile.                            | Toujours : réduit les hallucinations et permet la vérification.                       |
| Avancé / agentic | Self-RAG · Corrective RAG (CRAG) · Adaptive RAG | Le système juge si le contexte est suffisant, re-cherche si besoin, ou décide de ne pas répondre.                     | Enjeux de fiabilité élevés ; questions hétérogènes.                                   |
| Avancé / agentic | GraphRAG · RAPTOR (index hiérarchique)          | Structurer la connaissance en graphe / en résumés hiérarchiques pour les questions globales ou de synthèse.           | Corpus vastes ; questions « à l'échelle du document » plutôt que factuelles.          |

### 3 Quel problème → quelle technique

| SYMPTÔME OBSERVÉ                       | TECHNIQUES À ESSAYER (DANS L'ORDRE)                                                                                       |
|----------------------------------------|---------------------------------------------------------------------------------------------------------------------------|
| Le bon passage n'est pas récupéré      | Revoir le <b>chunking</b> → <b>recherche hybride</b> (dense + BM25) → <b>réécriture de requête</b> / HyDE.                |
| Trop de bruit dans le contexte         | <b>Re-ranking</b> (cross-encoder) → <b>MMR</b> pour diversifier → <b>compression</b> du contexte.                         |
| Questions complexes / multi-hop        | <b>Décomposition</b> en sous-questions → <b>multi-query</b> → <b>GraphRAG</b> pour les liens entre faits.                 |
| Le modèle hallucine malgré le contexte | <b>Citations</b> obligatoires → <b>Self-RAG</b> / <b>CRAG</b> (vérifier & re-chercher) → autoriser le « je ne sais pas ». |
|                                        |                                                                                                                           |

| SYMPTÔME OBSERVÉ              | TECHNIQUES À ESSAYER (DANS L'ORDRE)                                            |
|-------------------------------|--------------------------------------------------------------------------------|
| Réponses périmées             | Réindexer régulièrement → <b>métadonnées de fraîcheur</b> + filtrage par date. |
| Questions de synthèse globale | Index <b>hiérarchique (RAPTOR)</b> / résumés → <b>GraphRAG</b> .               |

#### 4 Évaluer un RAG — récupération ET génération, séparément

| DIMENSION                | CE QU'ON MESURE                                                    | COMMENT                                                                                |
|--------------------------|--------------------------------------------------------------------|----------------------------------------------------------------------------------------|
| Récupération             | Les bons passages sont-ils retrouvés, et bien classés ?            | Recall@k, Precision@k, MRR / NDCG (nécessite un jeu de questions → passages attendus). |
| Contexte                 | Le contexte fourni est-il pertinent (pas de bruit) ?               | Context relevance / precision (souvent via LLM-as-judge, ex. RAGAS).                   |
| Fidélité (groundedness)  | La réponse est-elle bien appuyée sur le contexte, sans invention ? | Faithfulness : vérifier que chaque affirmation est soutenue par une source.            |
| Pertinence de la réponse | La réponse répond-elle vraiment à la question ?                    | Answer relevance, revue humaine sur un échantillon.                                    |

**Le piège classique** : n'évaluer que la réponse finale. Si elle est mauvaise, on ne sait pas si c'est la **récupération** (mauvais passages) ou la **génération** (mauvaise synthèse). Mesure les deux séparément — dans 80 % des cas, le problème est la récupération.

**La règle d'or RAG**. Commence simple : un **chunking** correct, une **recherche hybride** et un **prompt ancré avec citations** couvrent déjà beaucoup. Mets en place une **évaluation** (récupération + génération) dès le départ, puis ajoute les techniques avancées (re-ranking, HyDE, décomposition, Self-RAG, GraphRAG) *uniquement là où la mesure montre le point faible*. Et rappelle-toi l'échelle GenAI : RAG avant fine-tuning.

À retenir. RAG = récupérer puis générer · la récupération est le maillon faible n°1 · commence par chunking + hybride + citations · mesure récupération et génération séparément · monte en **Annexe RAG · Série ML** complexité selon l'évaluation, pas par mode.

Pour aller plus loin (lecture) : « *RAG Made Simple* » de Nir Diamant et son dépôt public [RAG Techniques](#) (implémentations commentées de ces techniques).